CHARBEL DIB

Candidature en doctorat | Machine learning, NLP & évaluation

Paris, France · Mobilité France · charbel.dib@ensta.fr
charbel-dib.vercel.app | github.com/charbel-dib | linkedin.com/in/charbel-dib7

PROFIL

Ingénieur diplômé de l'ENSTA, avec une expérience de recherche en machine learning appliqué à la fabrication additive et en évaluation de systèmes RAG. Premier auteur d'un article IEEE. Recherche un doctorat en IA en France, avec un intérêt pour l'apprentissage à partir de données, le traitement du langage et l'évaluation expérimentale des modèles.

FORMATION

ENSTA, campus de Brest | Diplôme d'ingénieur | 2024 - 2026

Spécialité : Systèmes d'observation et intelligence artificielle.

Enseignements : machine learning, deep learning, vision, traitement du signal et fusion de données.

PUBLICATION

Charbel Dib, Rima Hleiss. *Cluster-Based Learning for Relative Density Prediction in Laser Powder Bed Fusion.* 2026 IEEE International Conference on Smart Sustainable Systems for Computer and Engineering Applications (3SCEA), 2026.

Premier auteur · DOI: 10.1109/3SCEA68071.2026.11603067

EXPÉRIENCES DE RECHERCHE

Astek Innovation Lab | Stage de fin d'études en NLP / RAG

La Défense, France · Mars - sept. 2026

Question : comment distinguer les erreurs de recherche documentaire, d'extraction de preuves et de classification dans un système de fact-checking climatique ?

- Structuré un cadre expérimental commun pour comparer les composantes du pipeline : segmentation, représentations denses, recherche hybride et reranking.
- Étudié l'extraction de preuves par LLM et ses formulations de prompts ; évalué un classifieur Phi-3 préalablement adapté par LoRA, en distinguant l'apport de chaque étape.
- Comparé des métriques de recherche et de classification (NDCG, rappel, macro-F1) et étudié une évaluation de la couverture des preuves par LLM juge.
- Analysé la propagation des erreurs à travers le pipeline et documenté les limites de l'évaluation ; organisé les exécutions avec Docker, cache et journaux d'expériences.

CESI / LINEACT | Stage de recherche en machine learning

Nanterre, France · Mai - août 2025

Question : comment relier les paramètres du procédé L-PBF à la densité relative des pièces fabriquées ?

- Construit et structuré une base expérimentale associant paramètres de fabrication et propriétés des pièces.
- Comparé des modèles prédictifs et étudié le clustering des configurations pour analyser les relations entre procédé et qualité.
- Contribué à la formalisation des travaux dans un article de conférence IEEE en premier auteur, avec Rima Hleiss.

PROJETS SCIENTIFIQUES & TECHNIQUES

Assistant documentaire ENSTA | Projet académique · 2026

Encadrement : Dr Abdelmalek Toumi · ENSTA

- Conçu un prototype RAG bilingue : collecte et nettoyage de sources web/PDF/XLSX, embeddings multilingual-E5, index FAISS et service FastAPI multi-session.
- Intégré citations, refus sous un seuil de similarité et transmission à un interlocuteur humain ; automatisé la reconstruction quotidienne du corpus web et de son index.
- Documenté les tests fonctionnels et les limites du prototype dans un rapport de projet : évaluation à grande échelle et validation utilisateur restant à mener.

FleetGuard | Projet personnel · 2026

- Étudié la classification déséquilibrée de défaillances APS sur le jeu public Scania : baselines, regroupement des doublons dans les partitions, calibration et seuil selon le coût des erreurs.
- Figé prétraitement, modèle et seuil avant l'évaluation finale. Test officiel de 16 000 observations : rappel 95,73 %, précision 43,05 %, 16 faux négatifs et 475 faux positifs.
- Publié une model card détaillant protocole, résultats et limites ; rendu les scores consultables via une API FastAPI et une interface React. Étude sur données publiques, sans validation en flotte réelle.

ServicePilot | Projet personnel · 2026

- Conçu un workflow de support avec LangGraph, FastAPI et SQLite : recherche de procédures et d'incidents, proposition figée, validation humaine puis autorisation de l'écriture côté serveur.
- Développé un SDK, des tests et des scénarios d'évaluation hors ligne sur données fictives ; mode déterministe par défaut, adaptateur LLM optionnel.

MÉTHODES & OUTILS

Évaluation : comparaison de baselines, analyse d'erreurs, NDCG, précision/rappel/F1, calibration, choix de seuil, documentation des protocoles et de leurs limites.

ML / NLP : Python, PyTorch, scikit-learn, XGBoost, Transformers, embeddings, recherche hybride, reranking, RAG ; Pandas, NumPy, SQL.

Prototypage : FAISS, FastAPI, LangGraph, Docker, Git, Linux.

DISTINCTION & LANGUES

1er prix, Hackathon SPASEA 2025 (Naval Group / DGA / ENSTA). Contribution en équipe à **posAIdon**, un copilote maritime associant données AIS, radiofréquences et éphémérides pour l'analyse d'anomalies.

Langues : français courant · anglais courant · arabe langue maternelle.